

PROYECTO DE TRABAJO DE FIN DE GRADO

Apellidos y nombre del alumno: Armas Ventura, Diego David
DNI: 42.239.314-K

Apellidos y nombre del tutor: Sánchez Berriel, Isabel
DNI: 42.885.838-S

Apellidos y nombre del co-tutor: Betancor Villalba, Rafael
DNI: 45.552.569-B

Título del Proyecto: “Catalogación ambiental de vehículos en Canarias mediante imputación de datos con técnicas de aprendizaje automático y enfoque DataOps-MLOps”.

1. Introducción

La inquietud creciente en torno a la calidad del aire y el cambio climático ha motivado la implantación de sistemas de clasificación ambiental para vehículos, siendo un ejemplo claro las etiquetas de la Dirección General de Tráfico (DGT). Estos distintivos permiten una rápida identificación del impacto contaminante del parque automovilístico [1]. En el contexto canario, la correcta categorización ambiental de los vehículos adquiere una relevancia particular. Esto se debe a la significativa concentración demográfica en áreas urbanas y a las particularidades geográficas del archipiélago, factores que pueden exacerbar los problemas de contaminación.

La construcción y el mantenimiento de sistemas de catalogación de vehículos requieren necesariamente disponer de datos completos y de alta calidad sobre sus características técnicas, que provienen en gran medida de fuentes oficiales como la DGT. No obstante, en la práctica, es habitual que estos conjuntos de datos presenten inconsistencias, valores faltantes o registros incompletos. Esta situación dificulta tanto el análisis como la toma de decisiones. Por consiguiente, la imputación de datos se vuelve un paso esencial para garantizar la integridad de la información y prevenir la introducción de sesgos en los modelos que se desarrollen posteriormente [2].

En este proyecto se propone el uso de modelos de aprendizaje automático para la imputación de datos faltantes relacionados con la catalogación ambiental de vehículos registrados en Canarias, con el objetivo de mejorar la calidad de los datasets derivados de la DGT para esta comunidad. Además, se plantea el desarrollo de una pequeña arquitectura basada en principios de DataOps y MLOps que permita automatizar, en la medida de lo posible, el flujo de trabajo de datos: desde la ingesta y el preprocesado, pasando por la imputación automática, hasta la generación de resultados y su evaluación.

2. Antecedentes y estado actual del tema

El sistema de distintivos ambientales de la Dirección General de Tráfico (DGT) clasifica los vehículos españoles según su impacto contaminante (etiquetas 0, ECO, C y B), basándose en la normativa de emisiones Euro, el combustible y la antigüedad [1]. Este sistema es fundamental para aplicar las restricciones de acceso en las Zonas de Bajas Emisiones (ZBE) y se ha consolidado como una pieza clave en las políticas de calidad del aire y movilidad sostenible en el país [1].

En Canarias, a pesar de que la implementación de las ZBE está menos avanzada, las futuras limitaciones de tráfico se regirán por este mismo sistema. Por ello, es especialmente crucial contar con un censo preciso del parque móvil y de su correspondiente etiqueta ambiental, dada la naturaleza insular y el alto grado de urbanización del territorio [3].

El manejo de valores ausentes constituye un desafío clásico en la estadística y la ciencia de datos. La literatura especializada abarca desde métodos de imputación sencillos (como la sustitución por la media, mediana o moda) hasta enfoques más sofisticados y basados en modelos, incluyendo regresión, k-Nearest Neighbors, árboles de decisión, bosques aleatorios o la imputación múltiple (e.g., MICE). Estos últimos buscan preservar de manera más efectiva las propiedades estadísticas del conjunto de datos [2].

Las prácticas recomendadas en este campo sugieren un proceso riguroso que implica: analizar el patrón de ausencia de datos, comparar las distribuciones de variables antes y después de la imputación, y cuantificar el error introducido por cada técnica aplicada.

Recientemente, se han explorado trabajos que integran técnicas de aprendizaje automático para optimizar la imputación en conjuntos de datos tabulares reales. Si bien estos modelos avanzados han demostrado potencial para reducir el error en ciertos contextos, la selección del método óptimo sigue siendo intrínsecamente dependiente de las características específicas de los datos y del porcentaje de valores ausentes [2]. Se han encontrado algunos trabajos sobre imputación de datos medioambientales como [4], [5] enfocados a empresas. Otros trabajos que tienen relación son [6] y [7], donde se obtiene una estimación de los kilómetros recorridos por el parque automovilístico en España utilizando técnicas de aprendizaje automático.

3. Actividades a realizar

1. Investigación de la metodología, herramientas y modelos
 - Revisión de la normativa de catalogación ambiental de la DGT y su aplicación en Canarias.
 - Estudio de técnicas de imputación de datos (métodos estadísticos y de aprendizaje automático) y selección de aquellas más adecuadas para datos de vehículos.
 - Revisión de conceptos y buenas prácticas de DataOps y MLOps aplicados a proyectos de ciencia de datos.
2. Detección y preparación de fuentes de datos
 - Identificación de conjuntos de datos de vehículos con información relevante para la catalogación ambiental (datos de la DGT y, en su caso, fuentes complementarias públicas).
 - Análisis exploratorio de los datos: tipos de variables, porcentaje y patrón de valores faltantes, detección de inconsistencias.
 - Definición del esquema de datos objetivo y preparación del dataset de trabajo (limpieza inicial, normalización de formatos, selección de variables).
3. Desarrollo siguiendo la metodología DataOps-MLOps
 - Diseño de una pipeline de datos que incluya ingesta, preprocesado, imputación y generación de salidas (informes o ficheros procesados).
 - Implementación de distintos modelos de imputación (por ejemplo, imputación simple, kNN, modelos supervisados) y selección del modelo final en función de métricas de error de imputación.
 - Integración de la imputación en la pipeline automatizada, utilizando herramientas y prácticas inspiradas en DataOps (scripts reproducibles, control de versiones, orquestación básica si procede).
 - Incorporación de comprobaciones de calidad de datos antes y después de la imputación (porcentajes de nulos, rangos válidos, coherencia entre variables).
4. Valoración de resultados
 - Definición de métricas para evaluar la calidad de la imputación (por ejemplo, error medio entre valores reales y estimados en un conjunto con valores simuladamente faltantes).
 - Análisis del impacto de la imputación en la catalogación ambiental: comparación de resultados con y sin imputación, identificación de posibles cambios en la asignación de etiquetas.
 - Discusión de las ventajas e inconvenientes del enfoque propuesto, así como de la viabilidad de su uso en un entorno real en Canarias.
 - Identificación de posibles líneas de mejora o ampliación futura (más datos, modelos más complejos, despliegue en producción, etc.).

4. Plan de Trabajo

Fase 1. Análisis y planificación (semana 1-2)

- Revisión bibliográfica sobre catalogación ambiental, imputación de datos, DataOps-MLOps.
- Definición de objetivos

Fase 2. Obtención y preparación de datos (semana 3-5)

- EDA → Análisis Exploratorio de Datos
- Depuración de los datos de la DGT
- Estudio de los valores faltantes y construcción de dataset

Fase 3. Diseño e implementación de modelos de imputación (semana 6-10)

- Selección de técnicas de imputación y definición de experimento
- Implementación y entrenamiento. Comparación de resultados.

Fase 4. Diseño e implementación de la pipeline DataOps (semana 11-13)

- Diseño de la arquitectura de la pipeline de datos.
- Implementación de los pasos de ingesta, preprocesado, imputación y generación de resultados de manera automatizada y reproducible.
- Inclusión de verificaciones básicas de calidad de datos.

Fase 5 – Evaluación y redacción de la memoria (semana 14-15)

- Evaluación de resultados, análisis crítico y elaboración de conclusiones.
- Redacción y revisión de la memoria del TFG y preparación de la presentación.

5. Bibliografía

[1] Dirección General de Tráfico, "Distintivo Ambiental," Ministerio del Interior, Gobierno de España. [En línea]. Disponible en: <https://www.dgt.es/nuestros-servicios/tu-vehiculo/tus-vehiculos/distintivo-ambiental/>

[2] J. S. Brownlee, "Iterative Imputation for Missing Values in Machine Learning," *Machine Learning Mastery*, 2020. Disponible en: <https://machinelearningmastery.com/iterative-imputation-for-missing-values-in-machine-learning/>

[3] Instituto Canario de Estadística (ISTAC), "Parque de vehículos por islas y tipos de vehículos," Gobierno de Canarias. [En línea]. Disponible en: <https://www.gobiernodecanarias.org/istac/> .

[4] Han, Y., Gopal, A., Ouyang, L., & Key, A. (2021). Estimation of corporate greenhouse gas emissions via machine learning. *arXiv preprint arXiv:2109.04318*.

[5] Caprioli, S., Foschi, J., Crupi, R., & Sabatino, A. (2024). Denoising ESG: quantifying data uncertainty from missing data with Machine Learning and prediction intervals. *arXiv preprint arXiv:2407.20047*.

[6] Narváez-Villa, P., Arenas-Ramírez, B., Mira, J., & Aparicio-Izquierdo, F. (2021). Analysis and prediction of vehicle kilometers traveled: A case study in Spain. *International Journal of Environmental Research and Public Health*, 18(16), 8327.

[7] Estimation of the distance travelled yearly by the vehicle fleet for the year 2023. DIRECTORATE-GENERAL FOR TRAFFIC. National Road Observatory (2023).

6. Propuesta de evaluación

Si se consigue	Calificación
Obtención y depuración de datos de la DGT; análisis exploratorio y documentación de los valores faltantes.	4
Diseñar, implementar y comparar diferentes modelos de imputación de datos	8
Diseñar e implementar la pipeline de datos con enfoque DataOps-MLOps	10

La Laguna, _____ de _____ de 2026

Fdo.: _____